NA

NOAHSARK · AI TEST PLATFORM

NoahsArk 方案

AI 资深测试工程师平台
总体方案 v2 · M0 设计评审版

本 PDF 已嵌入两张流程图：图 5-1 主流程、图 5-2 判定与失败边界。无需依赖 Markdown 的 Mermaid 渲染器。

2026-10-26　　状态：M0 待评审　　不包含产品实现

> 文档编号：NoahsArk-SOLUTION-v1.0
>
> 日期：2026-10-26
>
> 状态：设计定稿候选，等待方案评审与 UI 设计评审
>
> 当前闸门：方案与 UI 设计完成并获批前，不进入产品实现
>
> 工程基线：`IMPLEMENTATION-PLAN.md` 、OpenSpec change

---

0. 文档定位与约定

0.1 文档之间的关系

NoahsArk 的方案材料分为四层，职责不同，不能互相替代。

文档	角色	效力
`IMPLEMENTATION-PLAN.md`	决策完整版实施计划，包含 D1 至 D13、契约、门禁、81 个复选框	工程决策基线
`openspec/changes/ai-test-platform-v2/`	正式变更边界，包含 proposal、design、tasks 与 9 个能力增量	规格与评审基线
本文 `SOLUTION.md`	统一叙述产品愿景、架构、主流程、模块、路线图与需求追溯	方案说明，不新增契约
`laodengAi/csjh/2026-10-26/` 、`laodengAi/knowledge/`	产品意图、知识库审计、验证方法论与术语	输入材料，不是契约

发生冲突时，按以下顺序裁决：`IMPLEMENTATION-PLAN.md` 与 OpenSpec 契约优先，本文其次，`laodengAi` 方案作为产品意图参考。本文不修改任何既有契约，只把分散的产品意图和工程决策收束成一份可评审的整体方案。

0.2 状态标记

全文使用四种标记，避免把设想写成事实。

标记	含义
【已决】	已由实施计划、OpenSpec 或用户确认，可以直接作为设计与实现依据
【待定】	需要用户决策、后续设计或真实环境验证，当前不能写成承诺
【外部依赖】	依赖仓库权限、设备窗口、Webhook 目标、模型配额等外部条件
【缺口】	已知材料或文档存在缺失、计数不一致或尚未建立的内容

0.3 需求覆盖

本文覆盖 11 项平台需求。逐项映射见第 12 节。阅读顺序建议为：第 1 至 3 节理解定位，第 4 至 5 节理解架构与流程，第 6 至 9 节理解模块与治理，第 10 至 12 节理解落地与验收。

---

1. 执行摘要

NoahsArk 不是测试执行器（test runner）。它是一个会思考、会动手、会积累的 AI 资深测试工程师平台。

传统测试平台回答的问题是"把这个脚本跑起来"。NoahsArk 先回答"这个需求应该怎么测"，再回答"用哪套工具、哪台设备、哪种证据来证明"，最后才进入执行。它把项目知识、工具知识、历史任务、失败根因和脚本修复连成一条可追溯的工作链。

平台具备三种核心能力。

1. **会想**：任务进入后，先检索项目知识库，回答"这个项目怎么测"；再检索工具知识库 lstest，回答"用什么框架、什么 profile、什么执行入口"；然后生成带需求追溯的方案、用例和可证伪 oracle。
2. **会做**：在真实节点、真实设备、真实串口和声卡上预执行与正式执行；执行中自行诊断和修复测试逻辑、环境与脚本问题；修复后重新验证，不把测试自身的问题写成产品 FAIL。
3. **会记**：任务结束后写入任务 playbook、失败案例、根因和脚本修复；知识以 candidate 身份进入，经复核后才晋升；下一次相似任务能直接复用上一次的方法。

平台与普通测试平台的关键差别有五点。

- **知识优先，而不是提示词优先**：方案先由检索到的项目方法和工具契约支撑，再由模型补全。
- **oracle 必须可证伪**：预期结果绑定需求、证据来源和分母规则，不能由"脚本说 PASS"循环自证。
- **完成必须有真实执行凭证**：真实节点签名回执、租约、端点身份、产物清单哈希，缺一不可；dry-run、模拟、录制、回放不能作为完成证据。
- **完成是门禁对象，不是状态字符串**：C1 至 C7 逐项有证据，终态写入受数据库触发器和看门狗约束。
- **知识回写是任务的一部分**：没有 playbook 或明确的"无可复用知识"理由，任务不能归档。

【已决】平台成功的定义是：Phase 8 的全部门禁在真实设备上通过，并且第二个此前未见过的任务能够检索并复用第一个任务的 playbook，不需要人重新解释测试方法。该定义来自实施计划第 1 节。

【已决】当前阶段只做方案与 UI 设计。方案和 UI 设计获批之前，不写产品代码。

---

2. 产品愿景与角色宪章

2.1 产品愿景

把"测试工程师"的能力变成平台能力：给一个任务，平台自己检索方法、调度节点设备、组织执行、解决问题、完成验证，并把过程中的经验沉淀为下一次任务的起点。项目越多，平台越懂这个项目；任务越多，平台越懂怎

么测。

NoahsArk 的品牌意象是"方舟"：把需求、设备、证据和知识装载起来，穿过不确定的测试过程，最终交付可追溯的结果。产品名与 logo 概念来自实施计划开头的产品定义。

2.2 角色宪章：12 条原则

以下 12 条不是宣传语，而是平台必须通过机制落实的行为约束。原则文本对应实施计划第 1.1 节，落地机制对应 OpenSpec `agent-openspec-config`、`completion-gate`、`knowledge-retrieval` 等能力。

#	原则	平台必须表现出的行为	落地机制
1	先澄清再执行	需求范围、验收标准、样本量、环境或 oracle 不明确时，先提问并记录答案；关键字段缺失时进入 `BLOCKED_HUMAN`	需求摄取、开放问题清单、人工确认门
2	基于风险的策略	按项目与设备风险决定测试深度、场景和样本量，不套统一清单	A/B 风险分级、覆盖矩阵、风险评审
3	知识优先顺序	先检索项目知识库回答"怎么测"，再检索工具知识库 lstest 回答"怎么构建与执行"，最后设计运行	检索包、引用、`no_history` 显式返回
4	可证伪的 oracle	预期结果可独立检查，绑定需求与证据；禁止循环断言，禁止"脚本说 PASS 就是 PASS"	类型化 oracle、独立重算、证据要求注册表
5	建立在 lstest 之上	使用 lstest 的框架、profile 和工具契约；不分叉、不复制 lstest；脚本是手段不是目的	工具知识库、版本锁、profile 编译
6	真实执行	真实节点、设备、串口、音频端点与脚本；dry-run、mock、replay 只能做准备，不能作为完成证据	执行回执、`run_mode` 校验、C2 门禁
7	像工程师一样诊断	区分产品、测试逻辑、环境、基础设施和需求问题；raw FAIL 必须先收敛，再成为最终 FAIL	14 步根因树、失败归类、复测链
8	拒绝假 PASS	证据不足时输出 `BLOCKED`、`WARN` 或 `TIMING_AMBIGUOUS`，不为了迎合请求者而给出无证据 PASS	证据充分性门禁、独立重算、完成契约
9	教会平台	回写 playbook、失败案例、根因、脚本修复、项目与工具知识；去重、版本化、标注适用边界	知识库生命周期、整编任务、候选晋升
10	解释决策	每份方案、用例、oracle 和结论都引用需求、方法和证据，不出现无解释结论	追溯矩阵、引用格式、评审模板
11	在正确时机升级给人	模糊、高风险、不可逆操作必须人工批准；支持接管和显式停止	人工审批门、接管租约、停止控制
12	可度量地改进	跟踪假 PASS 逃逸、评审发现、知识复用率、工具修复率和返工率，用指标改进下一次任务	角色记分卡、方案质量指标、E2E 证据

2.3 角色记分卡

【已决】P4-13 评估以下指标：需求澄清完整度、需求到用例的追溯率、oracle 独立性、假 PASS 逃逸次数、根因分类准确率、知识复用率、脚本与工具修复率、评审阻断项解决率、真实执行占比。指标不是装饰性报表，而是下一轮方案改进的输入。

2.4 明确不是什么

- 不是任务执行器：只负责跑脚本的平台不满足第 1 节的成功定义。
- 不是聊天界面：对话是交互方式，不是交付物；交付物是方案、证据、结论和知识。
- 不是提示词生成器：没有检索、类型化产物、确定性保证和对抗评审的方案不进入执行。
- 不是只信 runner 的仪表盘：runner PASS 必须被独立重算和证据门禁复核。
- 不是自动批准模型猜测的知识库：候选知识必须经过复核才能成为 approved。

---

3. 范围与非目标

3.1 范围内

11 项需求按四种能力归类。

能力	需求	主要模块
会想	相似任务检索与 playbook 复用；方案、用例、oracle 的质量保证	知识库、检索、规划、评审、保证
会做	运行时模型切换；真实执行；自修复；人工接管	模型、执行、节点设备、接管
会记	失败、日志、根因、脚本修复、项目与工具知识写回	知识库、失败挖掘、归档
可治理	版本锁与升级兼容；主动推送；完整 UI；OpenSpec 与 Agent 治理	工具链、事件推送、UI、Agent 配置

逐项需求与任务、证据的对应关系见第 12 节。

3.2 非目标

以下内容不在 v2 范围内，来源为实施计划第 2 节。

1. 不复用 legacy 平台的 UI、路由、模板、执行适配器、旧运行时、数据库结构或测试夹具。NoahsArk 是全新代码库；Flask + Jinja2 只是新项目的技术选择，不是对 legacy 平台的继承。
2. 不建立第二套工作流状态机。NoahsArk 自身只有一套新工作流作为状态真相。
3. 不允许模型或 Agent 直接写运行、租约、终态、已批准知识或发布状态。
4. 不自动把候选知识晋升为 approved，不以圆桌多数票作为验收门。
5. 不跨机器复制凭据，provider secret 不进入节点、知识库、日志或 UI。
6. 不接受“用 mock 通过”。mock、录制、回放只用于单元测试和预检，不能作为完成证据。
7. 不接受 dry-run、mock、replay 作为完成证据。执行层从第一条真实运行开始实现，不复用 legacy 平台的假执行路径。
8. 不做多租户 SaaS、计费或面向公网的认证体系重构。

3.3 本阶段边界

- 【已决】当前只交付方案与 UI 设计，不交付产品代码。

- 【已决】UI 设计由配套文档 `UI-DESIGN.md` 与线框负责，本文只描述信息架构与页面职责，不复制完整视觉规格。
- 【待定】C8"测试之测试"只有占位，验收语义尚未定义，详见 11.5 节。
- 【待定】平台自我迭代、自动修改平台自身代码、热升级平台服务，不在 v2 的 81 个任务中；`laodengAi` 方案把它列为设置模块能力，是否纳入后续版本需要单独决策。
- 【外部依赖】真实设备窗口、Webhook 目标、模型配额、仓库推送权限不在方案阶段解决。

3.4 与 legacy 平台的边界

【已决】NoahsArk 不复用 legacy 平台的 UI 和执行层。legacy 平台只能作为问题清单和反面参考，不能作为底座。

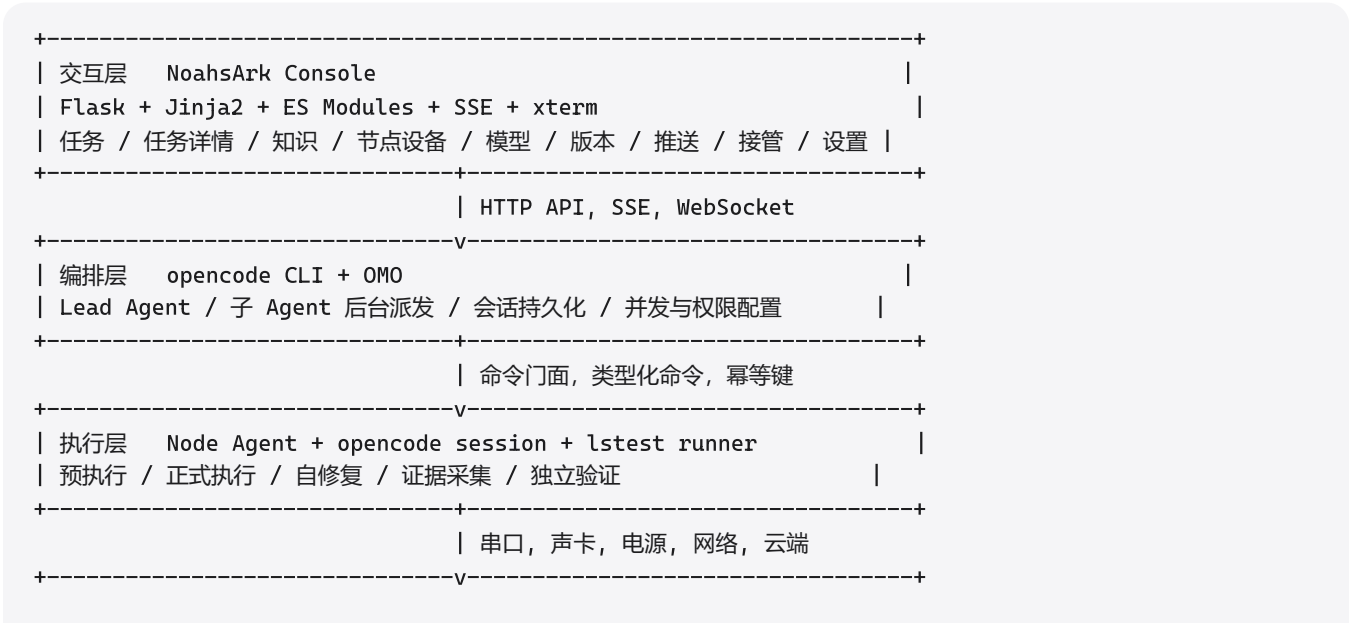
领域	允许参考	明确禁止
执行层	失败模式、门禁思想、设备测试经验	复用 旧运行时、mock/dry-run 执行路径、旧 runner、旧数据库状态、旧测试夹具
UI	信息密度、操作习惯的问题清单	复用旧模板、旧路由、旧样式、旧页面结构；NoahsArk UI 必须按 `UI-DESIGN.md` 重新设计
数据	历史问题的分类方式	复用旧表结构、旧状态字段、旧"已通过"结论
知识	已验证的方法论、术语、失败原因	把旧平台的假执行结果当作证据或 playbook

执行层的唯一可信证明是：真实节点、真实设备、真实脚本、真实证据、节点签名回执、独立复算。任一缺失都不能写成 PASS。

---

4. 总体架构

4.1 分层结构



```
| 设备层    节点 / 被测设备 / 端点身份 / 设备租约                          |
+-------------------------------------------------------------------+
| 能力层    项目知识库 / 工具知识库 lstest / 讨论插件                    |
+-------------------------------------------------------------------+
| 事实层    SQLite WAL：工作流 / 事件 / 证据 / 知识 / 门禁 / 交付        |
+-------------------------------------------------------------------+
| 治理层    OpenSpec / Agent Registry / Toolchain Lock / RBAC / 审计   |
+-------------------------------------------------------------------+
```

4.2 两个平面，一个事实源

【已决】架构采用两个平面，不允许第三个状态真相。来源为实施计划 D3 与 OpenSpec design。

平面	组成	能做什么	不能做什么
智能平面	Lead Agent、planner、case writer、script implementer、reviewer、圆桌	产出类型化候选工件与 `AgentEffect`；提出方案、用例、脚本、评审意见	不能直接写运行、门禁、租约、终态、已批准知识或发布状态
确定平面	工作流、权限、租约、派发、lstest、证据、验证、完成门禁、归档	拥有全部不可逆事实；执行命令、校验证据、写终态	不替 Agent 思考方案；不绕过门禁

Agent 可以提议，只有命令门面可以改变不可逆事实。任何"模型直接改数据库"的路径都视为架构违规。

4.3 交互层

【已决】交互层是全新的 NoahsArk 前端，采用 Flask + Jinja2 + 原生 ES Modules + SSE，不引入 Node 构建链；不复用 legacy 平台的 `server.py`、模板、静态资源或页面结构。视觉语言按 NoahsArk 品牌、方舟 logo 与新设计令牌重建。`xterm` 本地打包，支持内网离线使用。

- 新路由放在 NoahsArk 的 `app/api/`，由薄蓝图注册；不继承 legacy 平台的 `legacy-platform/aitest/platform/api.py`。
- NoahsArk API 统一位于 `/api/noahsark/v2/**`，页面位于 `/noahsark/**`。
- 前端共享 API 客户端负责 CSRF、401/403、事件游标与降级轮询。
- 页面只读投影命令 API，不直接拼装业务状态。
- UI 的完整页面规格、组件、断点、可访问性要求由 `UI-DESIGN.md` 负责，本文第 8 节只给信息架构。

4.4 编排层

【已决】编排层使用 opencode CLI 与 OMO。一个任务对应一个 Lead Agent 会话；Lead Agent 负责意图分类、检索、拆解、派发、汇总与报告。子 Agent 以后台会话执行，不阻塞 Lead Agent。

- 子 Agent 类型包括测试执行、代码搜索、资料查询、疑难诊断、计划审查等，按依赖 DAG 调度，无依赖并行。
- 并发上限、单模型并发、子 Agent 超时、重试次数、自动续跑由平台配置文件约束。
- 会话消息、工具调用、产物和证据持久化，支持列表、读取、搜索和回放。
- 权限矩阵复用 OMO 的工具限制：执行者可写，探索者与审查者只读，防止越权。
- 服务重启后未完成任务标记为中断，可显式恢复，不假装仍在运行。

4.5 执行层

【已决】执行层由 **全新实现** 的节点 Agent、opencode 会话和 lstest runner 组成。执行入口优先使用 lstest 的统一入口与 profile 契约，不为单个用例写一次性脚本。

【已决】执行层不复用 legacy 平台的 旧运行时、mock/dry-run 适配器、旧 runner、旧状态表或旧测试夹具。legacy 平台的执行只能作为反例阅读，不能作为 NoahsArk 的运行底座。

运行模式必须显式标注：`real`、`dry_run`、`simulated`、`recorded`、`replay`。只有 `real` 可以作为完成证据。真实运行必须带节点执行回执，回执至少包含节点 ID、租约 ID、串口与音频端点身份、runner 退出状态、产物清单哈希，并由节点密钥签名。

4.6 节点与设备层

节点是一台可执行测试的机器，记录 IP、SSH 或 Agent 通道、凭据引用、操作系统、已安装工具与版本、心跳状态。设备是挂在节点下的被测对象，记录机型、固件、串口角色与端口、声卡端点、适配项目、能力标签和租约持有者。

设备描述支持文本批量解析，例如把"COM3 空调 项目 A；COM5 音箱 项目 B"解析为结构化记录，减少手工录入。串口和音频端点必须使用稳定身份，不能只依赖会变化的 COM 编号。

同一串口或同一设备在任一时刻只能被一个任务占用。租约是确定平面的对象，Agent 不能自行抢占。

4.7 知识与能力层

平台有两类知识库，职责不同。

- **项目知识库**：回答"这个项目怎么测"。包含测试方法论、统计口径、指标定义、词表、场景、项目特性、历史 playbook、失败案例和项目事实。整体可用方法与项目特性必须分开，具体数值、词表、设备、项目名不能泛化为通用默认值。
- **工具知识库 lstest**：回答"用什么工具、怎么构建、怎么执行"。以 lstest 为核心框架，配合 trails 的工程规范、test-plan-architect 的方案构建能力，以及通用设备、音频、报告工具。工具条目必须登记能力、入口、输入输出、副作用、风险等级、适用项目和来源版本。

检索结果作为"不可信证据"注入 Agent 上下文，带引用、适用边界、差异、警告和反例。检索不能覆盖平台硬约束。

讨论插件是能力层的一个可调用工具，不是独立 Web 应用。它复用圆桌角色、议程、模型路由和会议记忆，返回共识、分歧、风险与行动项。

4.8 数据与持久层

【已决】数据层使用 SQLite WAL，设置 `busy_timeout=5000` 与 `foreign_keys=ON`。新 schema 通过幂等迁移创建，迁移前备份，支持回滚。PostgreSQL 是后续选项，不是 v2 依赖。

核心数据分为六组。

组	代表表	用途
事件	`platform_events`	追加式事件真相，供 UI、推送、CLI、审计消费
设置与模型	`platform_settings`、`model_bindings`、`model_switch_audit`、`task_model_overrides`	全局、Agent、任务级模型策略与切换审计
推送	`push_subscriptions`、`push_deliveries`、`push_dead_letters`	订阅、投递账本、死信
知识	`kb_entries`、`kb_revisions`、`kb_links`、`kb_feedback`、`kb_fts`、`task_playbooks`、`task_retrievals`	知识条目、修订、关联、反馈、全文索引、playbook、检索包
会话与接管	`executor_sessions`、`takeover_sessions`、`takeover_events`	原生 CLI 会话、接管租约与审计
门禁与回执	`toolchain_lock_runs`、`toolchain_smoke_runs`、`completion_reports`、`completion_gate_evidence`、`executor_receipts`	版本锁、冒烟、完成报告、门禁证据、执行回执

4.9 事件与推送层

【已决】所有有意义的状态变化追加到 `platform_events`，事件带单调 `seq`、唯一 `idempotency_key`、类型、严重度、任务 ID、发生时间、载荷和脱敏元数据。推送、UI SSE、CLI watch、检索指标和审计都消费同一份事件日志。

投递语义为至少一次，消费端按事件 ID 去重。推送失败不改变任务状态。渠道包括 SSE、终端、文件和 Webhook。Webhook 使用带时间戳的 HMAC-SHA256 与 URL 允许列表。

`task.completed` 每个任务只发一次，且必须在 C1 至 C7 与归档完成之后。失败、阻塞、停止分别使用 `task.failed`、`task.blocked`、`task.stopped`，不能冒充完成。

4.10 治理与安全层

治理层由 OpenSpec、Agent Registry、Toolchain Lock、功能开关、RBAC 与审计组成。安全基线包括统一脱敏、Webhook SSRF 允许列表、路径守卫、知识摄取秘密扫描、接管审计、受保护路径写入评审回执。详见 7.10 节与第 9 节。

4.11 部署形态

【已决】NoahsArk 是全新单进程 Flask 服务加 SQLite，多个节点 Agent 通过内网连接。平台不引入独立 SPA 服务、Node 构建服务或第二套消息中间件。该形态适合内网、单团队、可审计的测试场景；多租户与大规模横向扩展不在 v2 范围。

【已决】NoahsArk 的代码、数据库、模板、路由和执行适配器均从 NoahsArk 仓库开始，不继承 legacy 平台目录结构，也不依赖 legacy 平台进程或数据库。

---

5. 核心工作流

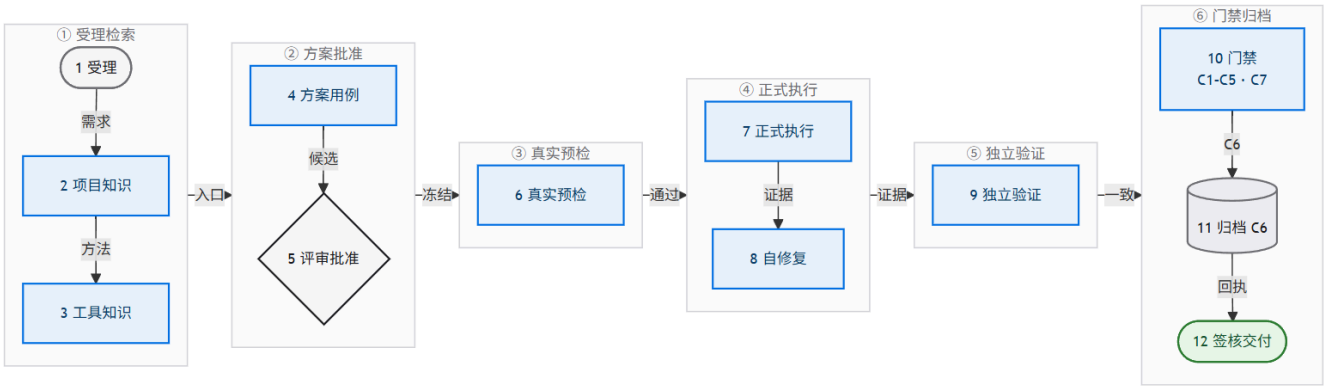
5.1 主干流程

平台的主干流程如下。顺序不能颠倒：项目知识决定"怎么测"，工具知识决定"怎么构建与执行"，方案评审通过后才允许真实预执行。

原来的单张流程图把主干、回环、人工等待、停止和 dry-run 判定画在同一张图里，节点超过 25 个，读者无法分清"正常路径"和"异常边界"。本节按"一图一问"拆成两张图：图 5-1 只画正常路径，图 5-2 只画判定与失败边界。统一图示规范见 `FLOWCHART-STYLE.md`。

5.1.1 图 5-1：12 个阶段与 6 个阶段带

一次任务按 ① 至 ⑥ 的顺序穿过六个阶段带：① 受理与检索（Intake + Retrieve）、② 方案与批准（Plan + Approve）、③ 真实预执行（Real Preflight）、④ 正式执行（Real Run）、⑤ 独立验证（Verify）、⑥ 门禁与归档（Gate + Archive）。每个节点对应 5.2 节表格中的一个可验收阶段，箭头上的短词表示阶段之间的交接物；本图只画正常路径，不画回环。

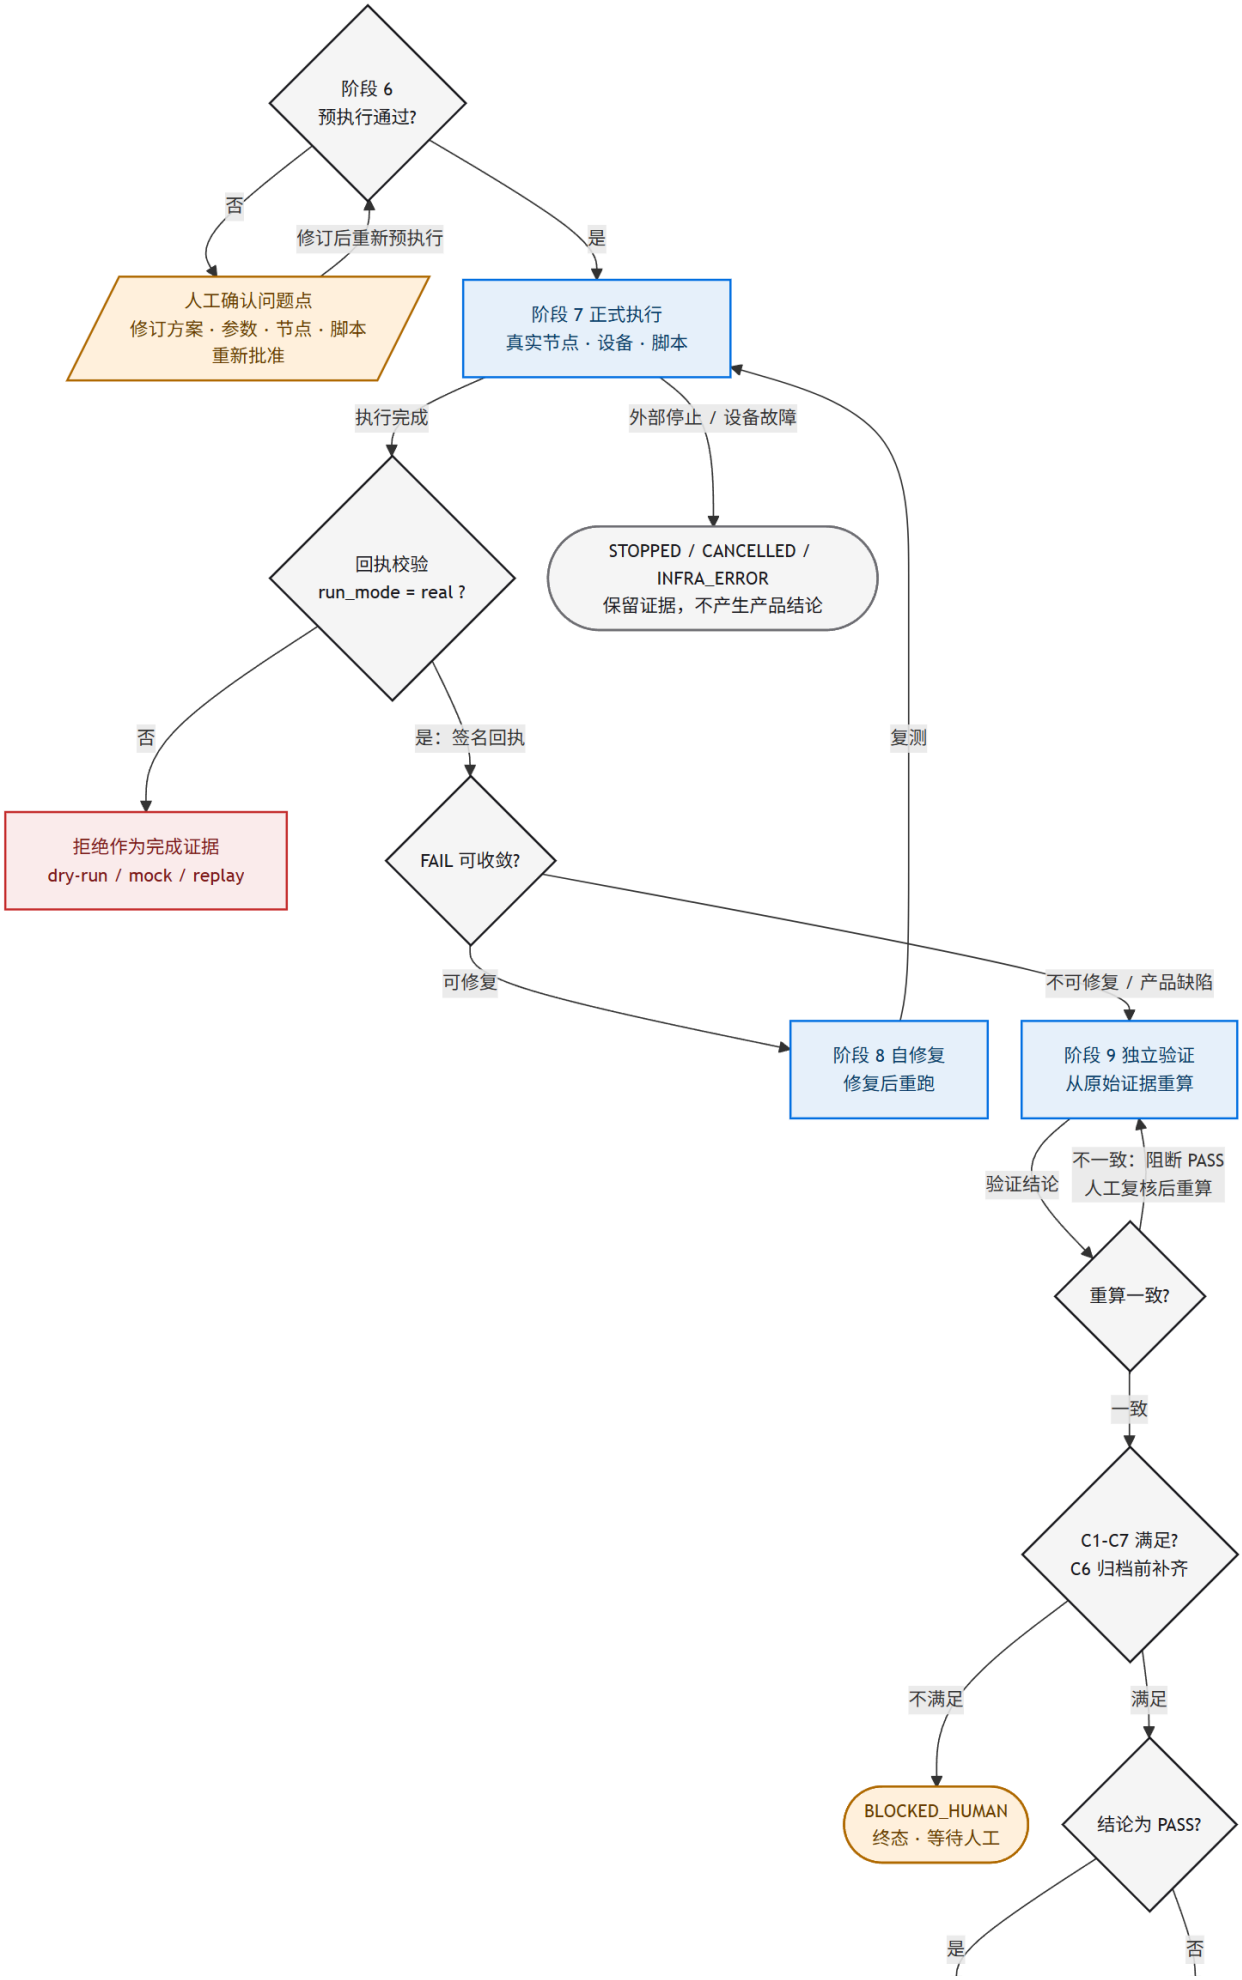


> 图 5-1 的渲染源：main-workflow.mmd · SVG。如果 Markdown 查看器不渲染 Mermaid，直接看上方 PNG。

图例：胶囊 = 开始/终态；矩形 = 动作；菱形 = 判定；圆柱 = 证据或归档；浅灰分组框 = 阶段带。颜色只作辅助（蓝 = 执行动作，绿 = 通过或完成，灰 = 边界与判定），状态含义由形状和文字承担，不依赖颜色。

5.1.2 图 5-2：判定与失败边界

本图只回答一个问题：在真实预执行、正式执行、独立验证和完成门禁之间，哪些判定会让流程回到上游、进入人工等待、被停止，或被拒绝作为完成证据。每条回环边都标出触发条件与返回点。


阶段 6
预执行通过?
否
修订后重新预执行
是
人工确认问题点
修订方案 · 参数 · 节点 · 脚本
重新批准
阶段 7 正式执行
真实节点 · 设备 · 脚本
执行完成
外部停止 / 设备故障
回执校验
run_mode = real ?
STOPPED / CANCELLED /
INFRA_ERROR
保留证据，不产生产品结论
否
是：签名回执
复测
拒绝作为完成证据
dry-run / mock / replay
FAIL 可收敛?
可修复
不可修复 / 产品缺陷
阶段 8 自修复
修复后重跑
阶段 9 独立验证
从原始证据重算
验证结论
不一致：阻断 PASS
人工复核后重算
重算一致?
一致
C1-C7 满足?
C6 归档前补齐
不满足
满足
BLOCKED_HUMAN
终态 · 等待人工
结论为 PASS?
是
否



> 图 5-2 的渲染源：decision-boundaries.mmd · SVG。如果 Markdown 查看器不渲染 Mermaid，直接看上方 PNG。

图例：沿用图 5-1 的形状与配色。琥珀色平行四边形 = 人工等待，H1 是预执行失败后的人工确认、修订与重新批准；琥珀色胶囊 = `BLOCKED_HUMAN` 终态，人工处理完成后按 5.3 重新发起执行，本图不画回边；红色 = 阻断或拒绝。`dry-run`、`mock`、`replay` 只能走到"拒绝作为完成证据"，不能走到 PASS；`FAIL` 只在需求矛盾或固件真实不满足时成立。

5.1.3 文本备用图（Mermaid 不可渲染时阅读）

对应图 5-1。

```
1  任务受理
       |
       v
2  项目知识库检索：这个项目怎么测
       |
       v
3  工具知识库 lstest：用什么构建、怎么执行
       |
       v
4  方案 / 用例 / oracle 生成
       |
       v
5  评审与人工批准（方案冻结）
       |
       v
6  真实预执行（脚本可执行性、环境门禁）
       |
       +---- 不通过 ----> 人工确认问题点 -> 修方案/参数/节点/脚本 -> 回到 5
       |
       v
7  正式执行（真实节点、设备、脚本、样本量）
       |
       v
8  自修复与 FAIL 收敛（只在可修复范围内）
       |
       v
9  独立验证（从原始证据重算结论）
       |
       v
10 完成门禁评估（C1 至 C7，C6 待回写证据）
       |
       v
11 知识回写与归档（补齐 C6：playbook、失败案例、根因、脚本修复）
       |
       v
12 完成签核、交付与主动推送（哈希报告定稿、交付清单、task.completed）
```

5.2 阶段说明

阶段	主要动作	产出与证据	失败与回退
1 任务受理	登记需求、资料、项目、设备、风险等级和来源清单；识别缺失字段与开放问题	任务 ID、来源清单、需求哈希、开放问题、风险分级	关键字段缺失进入 `BLOCKED_HUMAN`，不猜测
2 项目知识库检索	用需求、设备类别、标签检索方法、历史 playbook、失败案例、项目事实	版本化检索包，含命中理由、适用边界、差异、警告、引用；无命中显式 `no_history`	检索为空不阻断，但方案必须说明缺史依据
3 工具知识库检索	检索 lstest 入口、profile、validation pool、设备与音频工具、工程规范	工具选型、入口、副作用、风险等级、版本 pin	工具不匹配或版本漂移时回到方案或升级门禁
4 方案、用例、oracle	需求原子化、功能点建模、验证池匹配、覆盖矩阵、类型化用例与 oracle	`test_plan.v2`、用例集、oracle、证据窗口、追溯矩阵	多义变体标 `AMBIGUOUS`，未定义维度标 `TODO` 或 `BLOCKED`
5 评审与批准	对抗式多模型评审、确定性保证、人工批准、方案冻结	评审发现与解决回执、保证报告、批准人/时间、方案哈希	阻断项未解决不得批准；修改后生成新版本并失效旧执行
6 真实预执行	在真实设备上验证脚本可执行、环境就绪、串口/声卡/租约可用；样本量按项目配置，计划默认 10 次量级	预执行日志、门禁结果、环境快照；不作为完成证据	不通过必须人工确认问题点，修改后重新批准
7 正式执行	按批准方案在真实节点/设备执行；持续采集串口、音频、协议、工具日志与状态	原始证据、执行回执、产物清单、事件流	设备离线进入 `BLOCKED_HUMAN` 或 `INFRA_ERROR`；停止保留证据
8 自修复与收敛	诊断异常，区分测试逻辑、环境、设备、固件、需求、基础设施；修复后重跑	修复 diff、复测记录、收敛结论、根因候选	只有需求矛盾或固件真实不满足才保留最终 FAIL
9 独立验证	从原始产物和固定 oracle 重算机器结论，与 runner 结论比对；应用人工与业务策略	独立结论、分歧记录、证据图	分歧阻断 PASS；人工覆盖后机器结论保持不可变
10 完成门禁评估	评估 C1 至 C5 与 C7，列出 C6 回写义务，生成门禁草案；终态写入仍受触发器保护	门禁草案、C1 至 C5 与 C7 证据、C6 待办	任一必要门禁不满足则不得写终态
11 知识回写与归档	写 playbook、失败案例、根因、脚本修复；无复用价值时记录理由与操作者；补齐 C6 证据	`playbook_id`、知识候选 ID、C6 证据、归档回执	回写失败可断点续跑；不得跳过归档直接完成
12 完成签核、交付与推送	用 C6 证据签核哈希报告，写终态；生成交付清单与复现清单；推送结果到 UI、终端、文件、Webhook	最终完成报告、交付清单、复现哈希、`task.completed` 事件	推送失败只发警告，不改变任务状态

5.3 流程硬规则

【已决】以下规则写入平台硬约束，不由 Agent 自行判断是否遵守。

1. **预执行是硬门槛**：未通过预执行，不允许进入正式执行。预执行样本量是项目配置，计划默认 10 次量级；`laodengAi` 方案中的 10 次或 20 次作为可配置范围，不写成所有项目的固定值。
2. **不通过必须人工确认**：预执行不通过不是终点。任务触发者必须确认问题点、修改方案、参数、节点或脚本，然后重新批准。
3. **执行中可干预**：允许查看进度、追加信息、接管、停止和变更任务形态；所有干预留审计。

4. **结果必须可追溯**：每个结果都能回溯到任务输入、执行会话、证据文件、节点设备、脚本版本、模型绑定和工具链锁。
5. **禁止绕过**：不得用 `--skip-pretest`、缩短观察窗口、过滤额外识别、修改结果 CSV 等方式制造通过。
6. **dry-run 不是证据**：dry-run、mock、replay 只能用于准备、调试和单元测试。
7. **资源独占**：同一串口、同一设备、同一音频端点不能被并发任务同时占用。
8. **最终 FAIL 收敛**：只有需求矛盾、需求不可验证或固件真实不满足需求，才能保留最终 FAIL。

5.4 状态与终态

【已决】终态为 `PASS`、`FAIL`、`BLOCKED_HUMAN`、`CANCELLED`、`STOPPED`、`INFRA_ERROR`。`WAITING_HUMAN` 是非终态。没有 `DONE`。

阶段进度条是工作流状态的投影，不是第二套状态机。任务详情页展示的阶段、门禁和证据都必须来自同一工作流与完成报告。

5.5 静态保证、真实预执行与正式执行的边界

三个概念容易混淆，必须分开。

环节	是否接触真实设备	目的	能否作为完成证据
静态保证	否	校验 schema、追溯率、oracle 可证伪性、profile 可编译、lstest 预检不产生副作用	否
真实预执行	是	证明脚本能跑、环境就绪、端口与声卡可用、设备可唤醒	否
正式执行	是	按批准方案采集规定样本与证据，形成结论	是，且必须带执行回执
回放与复盘	否或只读	诊断历史执行、复核归因、生成失败候选	否

证据资格只由 `run_mode` 与执行回执决定：只有 `real` 可以进入 C2 并作为完成证据，`dry-run`、`mock`、`replay` 只能用于准备或调试。对应判定路径见 5.1.2 图 5-2。

静态保证在批准前完成，真实预执行在批准后完成。把静态保证当成预执行，或把预执行当成正式执行，都会制造假 PASS。

---

6. 功能模块

模块	职责	主要页面	关键契约
任务	受理、编排、进度、干预、结果与追溯	任务列表、任务详情	工作流状态、完成报告、交付清单
节点与设备	节点注册、设备登记、租约、健康	节点列表、节点详情	节点心跳、设备记录、租约

模块	职责	主要页面	关键契约
知识库	项目知识、工具知识、检索、评审、晋升	知识列表、知识详情	知识条目、修订、检索包
模型	目录、策略、热切换、审计	模型页	模型绑定、能力快照、切换审计
工具链与版本	版本锁、兼容矩阵、漂移、冒烟	版本页	`toolchain.lock.json`、兼容矩阵、冒烟记录
推送	订阅、投递、死信、测试发送	推送页	事件信封、投递账本、HMAC
接管	会话注册、附着、回放、输入、释放	任务详情接管页、终端页	接管租约、会话游标、幂等效果键
讨论插件	多角色、多模型的结构化讨论	由任务或 Agent 调用	`discuss` 工具契约
设置	全局模型、Agent、开关、保留策略、升级权限	设置页	平台设置、功能开关、审计

6.1 任务模块

任务是平台的核心工作单元。每个任务有全局唯一 ID，任务 ID 贯穿主 Agent 会话、子 Agent 会话、执行、证据、交付和知识。

- 任务列表支持按项目、状态、结论、设备、模型过滤；卡片展示需求摘要、项目、设备、进度、结论、证据数量和模型绑定。
- 任务详情是主要工作区，包含摘要、方案与用例、执行、证据、结论与门禁、知识、相似任务、接管、日志等视图。
- 任务窗口允许发布者在执行中追加信息、改变任务形态、与后台 Agent 沟通。
- 审批、开始、暂停、停止、接管、导出交付等动作必须经过权限校验和二次确认。
- 任务结果必须关联输入、会话、证据、节点、设备和脚本版本。

6.2 节点与设备模块

节点管理负责“在哪里执行”，设备管理负责“对什么执行”。

- 节点记录在线、陈旧、运行中状态，操作系统、CLI 版本、最后心跳和已安装工具。
- 设备记录机型、固件、串口角色与端口、音频端点、适配项目、能力标签、租约持有者。
- 支持粘贴文本自动解析设备清单，解析结果必须可人工修正。
- 节点详情提供受控的“问 Agent”窗口，用于扫描串口、登记设备等操作，所有动作审计。
- 租约冲突、设备离线、端点身份变化必须显式展示，不能静默重试到通过。

6.3 知识库模块

知识库分为项目知识与工具知识，共用条目、修订、关联、反馈和全文索引能力。

- 条目包含类型、范围、状态、来源、适用边界、证据引用、反例、版本和哈希。
- 状态生命周期为 `candidate`、`corroborated`、`approved`、`stale`、`retracted`，另有 `disputed`。
- 模型只能写 candidate；approved 需要评审回执和更高权限。

- 检索支持项目、设备、固件、工具 pin、状态、类型过滤，返回命中理由、冲突、反例和引用。
- 文档摄取支持 Markdown、文本、PDF 文本、DOCX、XLSX 文本，保留标题路径、来源、哈希，按内容哈希去重。
- 秘密与个人敏感信息扫描不通过时拒绝入库。

6.4 模型模块

模型模块管理"谁来思考"。目录记录提供方、模型 ID、家族、能力、健康、配额和目录版本。策略解析顺序为任务覆盖、Agent 覆盖、全局默认、编译期回退链。每次解析生成不可变绑定，记录来源、候选链、目录版本、能力快照、健康快照、修订号、操作者和原因。

- 支持全局、Agent、任务三种作用域切换。
- 默认在下一个回合边界生效；`interrupt` 必须显式请求，并只在安全检查点生效。
- 切换不重启进程。
- 瞬时错误切换到下一个候选；永久错误发 `MODEL_BLOCKED` 并转人工。
- 多模型评审至少保留两个模型家族；不足时发 `PANEL_DEGRADED`，不能宣称多模型评审。

6.5 工具链与版本模块

工具链模块回答"平台由什么组成、当前是否兼容"。

- 单一锁文件记录 opencode、OMO、自研插件、平台使用的 skill、Python、SQLite、lstest pin 和平台 commit 的版本与哈希。
- 兼容矩阵把版本范围映射到冒烟套件。
- 启动时校验锁；漂移时运行一级冒烟，真实执行默认关闭，直到确认。
- 版本页展示已安装、已锁定、兼容状态、最近冒烟、升级历史和锁文件下载。
- 禁止在页面展示二进制内容或 secret。

6.6 推送模块

推送模块负责把任务事件主动送到人所在的地方。

- 支持 SSE、终端、文件、Webhook 四类渠道。
- 订阅可配置事件类型、最低严重度、项目或任务过滤、渠道、目标和启停状态。
- 投递账本记录投递 ID、订阅 ID、事件 ID、尝试次数、状态、最后错误和下次尝试时间。
- 重试节奏为 1 秒、5 秒、30 秒、5 分钟、1 小时，之后进入死信。
- 测试发送只发合成 `push.test` 事件，不伪造任务结果。
- `task.completed` 只在完成门禁和归档之后发送，且只发一次。

6.7 接管模块

接管模块允许人在任务运行中接手，而不是只读日志。

- 目标可以是 Lead、工作单元或节点。

- 模式为 `observe` 或 `interactive`。观察模式为只读，可多人同时观察；交互式接管独占，通过租约 epoch 的比较交换避免双控制。
- Agent 在下一个回合边界暂停，设备动作执行中不得暂停。
- 接管后先回放历史，再接受输入；输入进入同一个原生 CLI 会话。
- 释放后从检查点恢复；已确认的副作用有幂等键，不重复执行。
- 默认空闲 30 分钟自动释放并发出事件。
- 所有接管动作审计，终态任务不可接管。

6.8 讨论插件

讨论插件把圆桌能力做成 OMO 可调用工具，不做房间、WebSocket、FastAPI 或 Vue 独立服务。

调用形式为 `discuss(topic, roles, models, max_rounds)`，返回共识、分歧、风险、行动项和引用。同轮多角色可并行，每轮结束由主 Agent 决定是否继续，最终总结由指定模型产出。讨论插件复用角色库、议程、模型路由和会议记忆，但产出只是候选意见，不是验收结论。

6.9 设置模块

设置模块管理平台级参数：全局默认模型、Agent 注册、功能开关、Webhook 与推送默认值、知识保留策略、真实设备窗口、升级审批人、审计查看。

- 功能开关默认关闭，未知值视为关闭，失败时关闭。
- 关键开关包括平台总开关，以及模型切换、推送、检索、完成门禁、接管、UI v2 等分项开关。
- 设置变更必须审计，涉及全局模型或真实执行的变更需要更高权限。
- 【待定】平台自我迭代、自动修复平台自身代码、热升级平台服务不在 v2 任务内，是否作为后续能力另行决策。

---

7. 关键机制

7.1 模型切换

【已决】解析优先级为任务覆盖、Agent 覆盖、全局默认、编译期回退链。每次解析生成不可变的模型绑定，至少包含绑定 ID、任务 ID、Agent 角色、解析来源、主模型、候选链、目录版本、健康快照、修订号、切换人和原因。

- 能力要求按用途声明：规划需要 JSON Schema，脚本实现需要工具调用，视觉或文档分析需要视觉能力。
- 瞬时错误包括超时、限流、不可用、5xx，进入下一个候选。
- 永久错误包括认证失败、模型不允许、预算不足，发 `MODEL_BLOCKED` 并转人工，不做静默降级。
- 面板多样性规则：健康家族少于两个时发 `PANEL_DEGRADED`，继续执行但明确说明，不宣称多模型评审。
- 默认在下一个回合边界应用。`interrupt` 只在安全检查点生效，设备动作中不打断。
- 切换不重启进程，进程启动时间不变；每次尝试写入模型使用记录，并带绑定 ID。

- 交付清单记录每个绑定的 ID、模型、角色和回合范围；绑定变化会改变复现清单哈希。

7.2 工具链版本锁

【已决】工具链锁是唯一版本真相。锁文件覆盖 opencode 的版本、commit、二进制哈希，OMO 的版本、git sha、入口哈希、工具契约哈希，每个自研插件的 ID、版本、git sha、入口哈希，每个平台使用的 skill 的 ID、`SKILL.md` 哈希、来源仓库与 commit，以及 Python、SQLite、lstest pin 与平台 commit。

兼容矩阵记录最低版本与最后测试版本，并把版本范围映射到冒烟套件。

层级	内容	时限	失败后果
T1	启动、只读页面、健康检查	60 秒内	平台可启动但禁止真实执行
T2	插件与工具契约、事件、推送、检索离线	数分钟	真实执行保持关闭
T3	模型、设备预检、一个真实任务	需要设备窗口	未通过不得进入 canary

升级流程固定为：快照、staging、T1/T2、影子 T3、canary、批准、回滚。版本 pin 更新是单独的受评审提交，不能夹带功能改动。漂移时真实执行失败关闭，直到所需冒烟被确认。

7.3 主动推送

【已决】事件信封至少包含 schema、单调序号、事件 ID、幂等键、类型、严重度、任务 ID、发生时间、载荷和脱敏元数据。所有事件先落库，再投递。

- 渠道为 SSE、终端、文件、Webhook。SSE 支持 `Last-Event-ID` 重放；文件按日期写 JSONL 并 fsync；终端写 NDJSON 并在 TTY 时发出提示；Webhook 带事件 ID、时间戳和 HMAC 签名。
- 投递至少一次，消费端按事件 ID 去重。最多 5 次尝试后进入死信。
- 推送失败发警告事件，不改变任务状态。
- `task.completed` 只在 C1 至 C7 与归档之后出现一次；重复完成尝试只产生一次通知。
- 阻塞与停止分别使用独立事件，不能复用 completed。

7.4 相似任务检索

【已决】任务创建时生成检索包，查询由需求文本、项目、设备类别和标签组成。检索包记录查询、命中列表、命中理由、状态、适用边界、可复用块、差异、警告和引用。无命中时返回显式的 `no_history`，不能假装有历史。

排序由 BM25、状态权重、范围权重、时效性和历史结果共同决定。approved 不能被 stale 或 disputed 静默压过。检索结果注入规划上下文时按“不可信证据”处理，必须带引用。

可复用块包括用例集、oracle、预检步骤和环境前置。复用不是复制结论：新任务必须重新验证适用边界，差异必须显示。

7.5 失败知识库

【已决】失败是知识资产，不是日志垃圾。

- 失败挖掘消费验证结果、证据图、失败用例、工具日志、串口日志签名和模型发现。
- 根因分类使用 14 步决策树，类别包括测试逻辑、环境、设备、固件、需求、基础设施和未知。
- 只有第 13 类需求矛盾或不可验证，以及第 14 类固件真实不满足需求，才能保留最终 FAIL；第 1 至 12 类必须先修测试逻辑、环境或断言并重跑。
- 失败案例与根因以 candidate 写入知识库，带证据引用和日志摘录，按任务、执行、类型和签名幂等。
- 根因为测试逻辑时写脚本修复候选，包含 diff、症状、修复和证据；不得自动修改已 pin 的工具，必须评审后才能共享。
- 周度整编任务可以提议合并近重复条目、标记陈旧候选、提出佐证升级，但永不自动批准。

7.6 完成契约

【已决】完成是门禁对象。`CompletionGate.evaluate(task)` 生成带哈希的报告，逐项引用证据。终态写入前必须有有效报告。

门禁分两步闭合。阶段 10 评估 C1 至 C5 与 C7，并列出 C6 的回写义务；阶段 11 执行知识回写与归档，补齐 C6 证据；阶段 12 用 C6 证据签核最终报告并写终态。这样既保留"先门禁评估、再知识回写"的顺序，也满足"C6 未满足不得归档"的硬约束。

门禁	要求	二值证据	不满足时
C1 方案	已批准且不可变的方案修订，保证通过，批准人和时间齐全	方案哈希、保证报告 ID、批准 ID	不得执行或完成
C2 真实执行	`run_mode=real`，节点签名的非零 runner 回执，租约 ID，端点身份	执行回执哈希、设备租约 ID、节点 ID	不得 PASS
C3 产物	产物清单哈希匹配，必需文件齐全，无路径穿越、截断或多余文件	清单哈希与逐文件哈希	证据不足
C4 结论	机器结论被独立重算，runner 与重算分歧已解决，人工和业务策略已应用	结论报告 ID、分歧解决记录	分歧阻断 PASS
C5 证据充分性	按用例类型具备必需证据，采集非空，分母有效	证据图 ID、逐用例证据引用	门禁不通过
C6 知识回写	任务 playbook 与失败条目已持久化，或有操作者记录的无复用知识理由	playbook ID 或知识候选 ID	归档前必须满足
C7 可复现	工具链锁哈希、lstest pin、模型绑定 ID、环境指纹齐全	复现清单哈希	不得完成

规则如下。

- `PASS` 需要 C1 至 C7 全部通过。
- `FAIL` 需要 C1 至 C5 与 C7，C6 在归档前必须满足。
- 执行前的 `CANCELLED` 可以跳过 C2/C3，但仍需归档回执，且不得宣称结论。
- `STOPPED` 与 `INFRA_ERROR` 保留产物并要求 C7，不产生产品结论。
- 数据库触发器拒绝"终态已写但没有合格完成报告"的写入。
- 看门狗在启动和每个周期扫描违规，发现后发出 `completion.invariant_violation`。
- 真实执行回执必须由节点密钥签名；过期或不匹配的租约失败；重复回执拒绝。

7.7 接管

【已决】接管是执行会话上的受围栏租约，不是裸 shell。

- 模式为观察或交互。交互式接管独占，通过单调 epoch 的比较交换获得。
- Agent 在下一个回合边界暂停，进入 `WAITING_HUMAN`；设备动作执行中不暂停。
- 接管先回放历史，再接受输入；输入路由到同一个原生会话。
- `interrupt` 在安全边界取消当前回合；恢复时发送检查点和最近消息。
- 已确认的副作用带幂等键，不重复执行；破坏性设备命令需要二次确认。
- 空闲超时自动释放并发出事件；陈旧 epoch 拒绝；所有动作审计。

7.8 可复现

【已决】每次交付生成复现清单，包含工具链锁哈希、lstest pin、方案/用例/oracle 哈希、模型绑定 ID、环境指纹、节点镜像与工具版本。清单使用稳定排序，任一输入变化都会改变哈希。

复现清单回答两个问题：这次结论由什么模型、什么工具、什么脚本、什么环境产生；另一个人能否在相同条件下重现。

7.9 方案质量保障

需求 11 要求"好方案、好用例、好 oracle"，不能靠提示词碰运气。平台采用五层保障。

1. **检索支撑**：项目方法与工具契约先进入上下文，方案引用来源，不凭空生成。
2. **类型化产物**：方案、用例、oracle 都是 schema 校验的结构化对象。用例包含需求引用、前置、动作、期望、禁止项、证据窗口、重试和断言；oracle 类型包括阈值、协议帧、日志序列、play ID、ASR、时间窗口和状态迁移。
3. **确定性保证**：检查需求到用例到 oracle 的 100% 追溯，检查 oracle 可证伪且绑定证据，检查项目值没有硬编码，检查 schema、profile 编译和 lstest 预检。
4. **对抗式多模型评审**：覆盖度、oracle 可证伪性、设备可执行性和风险分别评审；跨家族模型；阻断项必须解决或带操作者豁免。
5. **人工批准与指标**：B 类或高风险任务必须人工批准；A 类只有在保证通过、低风险且有明确策略时才可自动批准。方案质量指标持续跟踪追溯率、oracle 覆盖、评审阻断、假 PASS 逃逸、人工改写率和检索复用率。

7.10 安全与秘密

【已决】安全基线在加能力之前建立。

- 统一脱敏 authorization、cookie、token 和 key。
- RBAC 与所有者范围校验覆盖读写；接管与受保护写入审计。
- Webhook 只允许 HTTPS，校验时间戳与 HMAC，执行 SSRF 允许列表，默认禁止回环地址。
- provider 凭据留在服务端凭据代理，只持久化 `credential_ref`；secret 不进入节点、知识库、日志或 UI。
- 知识摄取扫描 secret 与 PII，保存摘要或指针，不保存原始敏感证据。

- 受保护路径写入需要评审回执；评审者家族不能等于作者家族。
- 产物与知识读取有路径守卫，防止穿越。

---

8. UI 概览

8.1 设计原则

UI 是平台事实的投影，不是第二套业务逻辑。

- 只读投影命令 API 返回的数据，写操作必须映射到命令门面。
- 任务详情必须同时展示阶段进度、门禁、结论、证据、交付和接管状态，不能只显示一个状态徽章。
- 任何页面都不能显示 secret、provider key、完整凭据或模型推理私有内容。
- SSE 断线时降级为有界轮询，并显示"实时/降级"状态；不能静默展示过期数据。
- 结论、证据和可执行动作在桌面、平板、手机上都不能被隐藏。
- 品牌使用 NoahsArk 与方舟意象，视觉规格由 UI 设计文档确定。

8.2 信息架构

最终站点地图与视觉规格由 `UI-DESIGN.md` 与线框负责。本文约定页面职责。

页面	回答的问题	关键内容
总览	平台现在健康吗	运行中、阻塞、完成、待人工、门禁失败、推送死信、工具链漂移、模型健康、快捷入口
任务列表	有哪些任务，进展如何	项目、状态、结论、设备、模型、进度、证据数量、过滤与排序
任务详情	这个任务发生了什么	摘要、方案与用例、执行、证据、结论与门禁、知识、相似任务、接管、日志
知识	平台知道什么，是否可信	搜索、类型/范围/状态过滤、来源、证据、反例、冲突、修订、晋升与退役
节点与设备	在哪里执行，设备是否可用	节点在线与心跳、CLI 版本、设备型号与固件、串口与声卡、租约、节点任务窗口
模型	谁在思考，切换是否生效	全局默认、Agent 覆盖、任务覆盖、生效绑定、候选健康、能力、测试调用、审计
版本	平台由什么组成	opencode、OMO、插件、skill、lstest、Python、SQLite 的安装/锁定/兼容矩阵、漂移、冒烟
推送	结果送到了哪里	订阅、渠道、过滤、测试发送、投递时间线、死信重试
Agent	谁负责什么	角色、模型策略、上下文包、命令、写范围、工具、评审要求
系统	平台如何配置与审计	功能开关、保留策略、升级审批、审计、运行手册入口

接管终端是任务详情下的工作视图，不作为独立业务模块。讨论能力由 Agent 在任务中调用，页面只展示讨论结果和引用。

8.3 任务详情视图

任务详情至少包含以下视图。

- 摘要：需求、项目、设备、风险等级、当前阶段、结论、模型绑定。
- 方案与用例：覆盖矩阵、用例列表、oracle、追溯关系、批准记录。
- 执行：预执行与正式执行记录、样本进度、节点与设备、运行模式、执行回执。
- 证据：按用例组织的串口日志、音频、工具日志、结果表、截图和哈希。
- 结论与门禁：C1 至 C7 逐项状态、证据引用、报告哈希、阻断原因。
- 知识：本次生成的 playbook、失败候选、根因、脚本修复。
- 相似任务：命中理由、可复用块、差异、警告、引用；允许把可复用块应用为方案草稿修订。
- 接管：观察/交互状态、控制者、历史回放、输入、释放。
- 日志：事件流、命令审计、模型使用和工具链信息。

8.4 状态矩阵

每个页面必须覆盖加载、空、错误、阻塞、陈旧和降级状态。任务详情还要覆盖等待人工、预执行失败、正式执行中、自修复中、验证分歧、完成门禁失败、已接管和已停止。状态不是颜色装饰，必须带文字说明和下一步动作。

8.5 与 UI 设计文档的关系

`UI-DESIGN.md` 由配套 UI 设计任务负责，当前已落盘并等待用户评审。它包含品牌、站点地图、逐页规格、组件、断点、可访问性、交互说明和线框。完整规格见 `UI-DESIGN.md`。本文只定义页面职责和信息架构，不复制完整视觉规格，也不修改 UI 文件。UI 设计评审通过是进入 P7 实现的前置条件。

---

9. OpenSpec 与 Agent 治理

9.1 需求到变更

【已决】需求先进入 OpenSpec 变更，再进入实现。变更包含 proposal、design、tasks 和能力增量规格；批准前运行严格校验。需求、方案、用例、脚本和评审都能回溯到同一个变更边界。

现有 v2 变更包含 9 个能力增量：`model-policy`、`platform-events-push`、`knowledge-retrieval`、`task-playbook`、`completion-gate`、`takeover-session`、`toolchain-compatibility`、`agent-openspec-config`、`ui-v2`。

9.2 Agent 角色

【已决】角色注册表是唯一配置源。角色至少包括 Lead、planner、case writer、script implementer、reviewer、oracle、device 和 knowledge curator。

角色	主要职责	写范围	评审要求
Lead	任务编排、派发、汇总、升级	任务工作区与编排产物	关键决策需人工确认
Planner	需求分析、方案与覆盖矩阵	本地方案目录	方案评审与保证

角色	主要职责	写范围	评审要求
Case Writer	用例与 oracle 草案	方案与用例目录	用例评审
Script Implementer	基于 Istest 实现脚本与 profile	OpenSpec 任务文件与源码受控范围	脚本评审
Reviewer	覆盖、oracle、可执行性、风险评审	只读	不能评审自己家族的产物
Oracle	独立结论与分歧分析	只读或受限输出	结论复核
Device	节点与设备操作	受控设备命令	破坏性操作二次确认
Knowledge Curator	知识整编、去重、晋升建议	知识候选区	晋升需人工批准

9.3 上下文包与生成配置

每个角色声明模型策略、OpenSpec 上下文包、允许的 OpenSpec 命令、写范围、工具、技能和是否需要评审。注册表渲染为 `.opencode/agent/*.md`、`opencode.json` 中的 Agent 条目和上下文包文档。

- 手写生成文件视为漂移，CI 拒绝。
- 注册表非法时失败关闭。
- 角色不能获得超出职责的工具；审查者只读。
- 上下文包把该角色需要的规格、模板、方法论文档打包，避免把所有规范塞进一个提示词。

9.4 评审门

方案、用例和脚本分别有评审模板与严重度定义。评审覆盖需求追溯、oracle 可证伪性、设备可执行性、风险、证据充分性和安全。

- 阻断项必须解决，或有操作者、理由和证据的明确豁免。
- 确定性保证不能由模型自己批准自己。
- 受保护路径包括 OpenSpec、Agent 配置、平台本地状态和项目资产；没有评审回执的写入被命令门面拒绝并审计。
- 评审者模型家族不能等于作者家族。
- 受保护路径的人工作签是必须的。

9.5 不可写事实

Agent 可以写方案、用例、脚本草案、评审意见和知识候选。Agent 不能写运行记录、租约、终态、已批准知识、发布状态和受保护配置。所有不可逆动作通过命令门面，带幂等键和审计。

---

10. 分阶段路线图

10.1 阶段总览

阶段	目标	关键产出	退出条件
Phase 0 基础层	冻结契约、迁移、事件、测试与安全基线	蓝图、schema、契约校验器、事件日志、测试夹具、安全基线、ADR	第 0 波门禁通过；契约冻结；所有开关关闭
Phase 1 模型	目录、策略、热切换、回退、API、CLI、交付快照	模型目录、解析器、切换审计、回退策略、模型页面数据	切换无需重启；审计与绑定可追溯
Phase 2 推送	可靠投递、四类渠道、订阅、CLI watch	outbox、投递账本、SSE/文件/终端/Webhook、订阅 API	至少一次投递、去重、完成只通知一次
Phase 3 知识	统一知识库、检索、playbook、失败挖掘、文档摄取、回填	KB schema、检索包、失败根因、脚本修复、知识 API	检索可解释；失败知识可候选化；旧知识可回填
Phase 4 规划与治理	需求摄取、功能建模、方案/用例/oracle、评审、保证、审批、Agent 配置、讨论插件	结构化方案、保证报告、评审模板、Agent 注册表、讨论工具	方案可追溯、可证伪、可执行；Agent 配置无漂移
Phase 5 完成契约	完成报告、证据要求、真实回执、独立重算、归档门禁	C1 至 C7、触发器、证据注册表、复现清单	假完成路径被阻断；终态必须有合格报告
Phase 6 接管	会话注册、附着、租约、回放、输入、恢复	会话注册表、接管租约、WebSocket 回放、CLI attach	接管不重复副作用；释放后可恢复
Phase 7 UI	设计系统、页面、终端、推送、知识、节点、可访问性	完整 NoahsArk 控制台页面、组件、SSE 客户端、视觉与可访问性检查	页面与后端契约一致；桌面/平板/手机可用
Phase 8 验证	版本快照、冒烟、真实 E2E、升级演练、可观测性、交付文档	工具链锁、升级手册、真实 PASS/FAIL/BLOCKED、演练证据、交付包	V1 至 V8 全部门禁通过；二元签核

10.2 依赖顺序

【已决】依赖安全顺序如下，来自实施计划第 16 节。

```
P0-01 -> P0-02 -> P0-03 -> P0-04
      -> P0-05 / P0-06 / P0-07 / P0-08
      -> Phase 1 / Phase 2 / Phase 3 / Phase 4 并行轨道
      -> Phase 5 -> Phase 6
      -> Phase 7 逐页实现
      -> P8-01 / P8-02 -> P8-03
      -> P8-04 / P8-05 -> P8-06 / P8-07
      -> P8-08 / P8-09 -> P8-10
```

Phase 0 的共享文件在冻结后只能由轨道负责人修改。Phase 1 至 Phase 4 可以并行，但共享契约变更必须回到 Phase 0 的规则。Phase 5 依赖方案批准与知识写回。Phase 6 依赖会话注册与推送。Phase 7 依赖各页面 API 稳定。Phase 8 依赖真实设备与 UI 完成。

10.3 里程碑

里程碑	内容	判定
M0 设计批准	本方案与 UI 设计完成评审	用户批准，进入实现
M1 地基可用	Phase 0 完成	契约冻结、迁移可通过、事件可重放
M2 智能闭环	Phase 1 至 Phase 4 完成	检索、方案、评审、模型切换可用
M3 结果可信	Phase 5 至 Phase 6 完成	完成门禁、真实回执、接管可用
M4 界面完整	Phase 7 完成	页面、可访问性、契约测试通过
M5 真实验收	Phase 8 完成	真实 PASS/FAIL/BLOCKED、升级演练、签核

10.4 任务计数与文档同步状态

【已同步】实施计划、OpenSpec `tasks.md`、proposal 和 README 统一为 81 个复选框：Phase 0 为 8，Phase 1 为 7，Phase 2 为 6，Phase 3 为 10，Phase 4 为 13，Phase 5 为 7，Phase 6 为 6，Phase 7 为 14，Phase 8 为 10。P4-11、P4-12、P4-13 与 P7-00 已纳入，任务 ID 无缺失。

P4-12 仍依赖 P5-03，不能按 Phase 4 单独关闭；其 C8 语义仍按 11.5 节保持占位，待整体方案方向确认后再定义。

10.5 当前闸门

【已决】当前只允许做方案与 UI 设计。M0 获批之前，不写产品代码、不启用功能开关、不修改生产数据。该闸门来自实施计划开头的执行模式说明。

---

11. 风险、决策与开放问题

本节把"已决""冲突裁决""风险""待定"分开写。11.1 只列已决架构决策，11.2 列来源冲突及裁决，11.3 列风险，11.4 列仍需用户或环境确认的问题，11.5 单独说明 C8 占位。

11.1 已决架构决策

编号	决策	后果
D1	**全新 NoahsArk 代码库，不复用 legacy 平台的 UI/执行层**	执行从真实运行开始实现；legacy 平台只作反例；无假执行继承
D2	**新 Flask + Jinja2 + 原生 ES Modules + SSE + SQLite WAL**	新项目技术选择；不引入 SPA 构建链；不使用 legacy 平台模板或路由
D3	两个平面，一个事实源	Agent 提议，命令门面写不可逆事实
D4	模型绑定是一等版本化对象	按任务、Agent、全局、编译回退解析，每次运行快照
D5	完成是门禁对象，不是状态字符串	终态写入必须有哈希报告

编号	决策	后果
D6	事件优先集成	追加式单调事件供 UI、推送、CLI、审计消费
D7	知识有证据范围与状态门	来源、适用边界、冲突、反例必须存在
D8	接管是受围栏会话租约，不是裸 shell	回合边界暂停、回放、输入、比较交换
D9	OpenSpec 是变更边界，Agent 配置生成	注册表为源，漂移与未评审写入失败关闭
D10	工具链兼容机器验证	锁、兼容矩阵、冒烟分层，漂移关闭真实执行
D11	真实运行证明可归因	签名回执、租约、产物清单
D12	功能开关默认关闭，失败关闭	未知值视为关闭，不静默回退旧完成
D13	安全与秘密是一等约束	凭据引用、HMAC、RBAC、脱敏、SSRF、审计

11.2 关键冲突与裁决

冲突	来源	裁决	状态
前端栈：Vue 3 + Element Plus + FastAPI，还是 Flask + Jinja2 + 原生 JS	`laodengAi` 总体方案第 1 节与实施计划 D2 冲突	NoahsArk 采用全新 Flask + Jinja2 + ES Modules + SSE；UI 由 `UI-DESIGN.md` 重新设计，不复用 legacy 平台 或 `laodengAi` 的页面代码	【已决】
执行层：复用 legacy 平台还是新写	用户明确 legacy 平台执行为假执行，不能作为底座	NoahsArk 执行层全部新写；旧 旧运行时、mock 适配器、旧 runner 只作反例；完成证据只接受真实运行	【已决】
主流程：9 步简化流程，还是 12 段带门禁流程	`laodengAi` 总体方案第 0.1 节与实施计划门禁体系	采用本文 12 段流程；9 步中的确认、预执行、人工确认规则保留	【已决】
验证池数量：18 个模块，还是 16 个注册模块	部分材料写 18 模块；深度知识文档审计为 16 个注册模块 + 1 个未注册文档 + 2 个治理文档	对外写“16 个注册验证模块 + 1 个候选文档 + 2 个治理文档”；不把 18 当作已验证功能模块数	【已决】
任务计数：77 还是 81	OpenSpec tasks.md 与实施计划实际复选框不一致	以 81 为唯一计划；实施计划、tasks.md、proposal、README 已同步	【已决】
知识库范围：27 个仓库是否全收	`laodengAi` 知识库分类方案	12 个整体纳入工具库，2 个只纳入方法层，9 个只提炼方法，4 个不纳入；最终摄取仍需评审	【已决】分类原则，【待定】最终清单
平台自我迭代是否属于 v2	`laodengAi` 设置模块包含自我迭代；实施计划无对应任务	不纳入 v2 的 81 个任务；作为后续能力单独决策	【待定】
预执行样本量是 10 还是 20	`laodengAi` 写 10 或 20；实施计划写预执行 10	预执行是硬门槛；默认 10 次量级，具体值按项目 profile 配置	【已决】门槛，【待定】项目值

11.3 风险与缓解

风险	后果	缓解
新应用路由与模块无边界	难以维护，回归风险高	P0-02 固定 `app/` 模块边界与蓝图注册；禁止把新逻辑塞进单文件

风险	后果	缓解
模型切换发生在设备动作中	执行中断或状态不一致	回合边界应用，安全检查点中断，接管租约
推送洪水或重复完成通知	用户不信任通知	事件分类、订阅过滤、幂等键、去重、预算
知识库被模型猜测污染	后续任务被错误方法误导	状态生命周期、来源必填、只写候选、人工批准
检索注入陈旧或错误历史	方案偏离当前需求	范围过滤、pin 与固件警告、冲突展示、不可信证据包装
完成门禁变成橡皮图章	假 PASS	二值证据、数据库触发器、看门狗、变异测试
接管竞争或双控制	重复设备动作	epoch 比较交换、交互独占、审计、超时
升级静默破坏插件	真实执行异常	契约快照、分层冒烟、漂移关闭真实执行
UI 与后端漂移	页面显示错误事实	路由清单测试、契约测试、生成导航、视觉检查
真实设备时间稀缺	验证延期	预执行与正式执行分离、租约复用、提前准备 E2E
误复用 legacy 平台的假执行或旧 UI	假 PASS、结果不可信、UI 返工	NoahsArk 新代码库；禁止导入 legacy 平台执行/模板；真实执行回执；独立 UI 设计评审
真实执行被 mock 或 dry-run 替代	完成证据无效	`run_mode` 必填；完成门禁只接受 `real`；节点签名回执；mock 只允许单元测试
过度自动化导致错误自信	无证据结论	角色宪章、独立验证、人工升级、拒绝假 PASS
知识泄露秘密或客户数据	合规与安全问题	摄取扫描、摘要与指针、保留策略、RBAC
模型配额或成本失控	任务停滞或费用超支	目录健康、预算、候选链、面板降级

11.4 开放问题

编号	问题	当前状态	影响
Q1	空仓库的推送身份与 token 所有者	【外部依赖】仓库已确定为 NoahsArk，SSH 22/443 曾重置，`GITHUB_TOKEN` 存在	影响代码托管与 CI
Q2	Webhook 地址、共享密钥所有者、是否还需要桌面通知	【待定】	影响推送渠道与验收
Q3	全局默认模型、至少一个回退家族、`listenai` 配额是硬阻断还是降级	【待定】	影响模型策略与面板行为
Q4	Phase 8 使用 TCL000 还是 TCL003，维护窗口，是否允许断电与离线模拟	【外部依赖】	影响真实 E2E 排期
Q5	原始音频、串口日志、模型会话保留多久；哪些项目数据不得进入知识库	【待定】	影响知识库与合规
Q6	opencode、OMO、lstest 的 pin 变更由谁批准，验收期是否冻结	【待定】	影响升级流程与责任
Q7	C8"测试之测试"的语义与验收标准	【待定】占位，见 11.5	影响"测试本身是否有效"的证明
Q8	UI 设计评审时间与批准人	【待定】	影响 P7 启动

编号	问题	当前状态	影响
Q9	`tasks.md` 与实施计划的任务计数	【已同步】81 项，任务 ID 无缺失	评审范围与任务追踪一致
Q10	`tmpskill` 目录级知识摄取范围	【待定】只完成仓库级审计	影响知识库首批内容
Q11	平台自我迭代是否进入后续版本	【待定】	影响设置模块与平台维护方式

11.5 C8"测试之测试"占位说明

【待定】C8 是"证明测试本身有效"的门禁，当前只有占位，没有验收标准。实施计划 P4-12 明确写明：依赖 P4-05 与 P5-03，文件、验收和验证方式在整体方案方向确认后再定，现在不发明标准。

可能的方向只作为候选，不是承诺：oracle 独立性检查、已知好与已知坏样本对照、变异检测、假 PASS 检查、测试脚本的负向自检。任何方向都要等整体方案落地并经用户确认后才能写成 P4-12 的验收条件。当前完成契约仍以 C1 至 C7 为准，C8 不参与 PASS/FAIL 判定。

---

12. 需求追溯

#	需求	本文对应	能力增量	主要任务	证明
1	运行时模型切换，支持全局、Agent、任务，带校验与回退，不重启	4.4、6.4、7.1	`model-policy`	P1-01 至 P1-07、P7-05、P8-06	策略与切换测试、实时切换探针、模型使用表
2	版本锁与升级后的机器验证兼容	4.10、6.5、7.2	`toolchain-compatibility`	P0-03、P1-01、P7-06、P8-01、P8-02、P8-07	锁文件、冒烟记录、升级演练证据
3	任务与结果主动推送到终端、文件、Webhook、事件总线	4.9、6.6、7.3	`platform-events-push`	P2-01 至 P2-06、P7-10、P8-04	投递账本、CLI watch 演示、Webhook 接收端
4	相似任务检索与 playbook 持久化复用	5.2、6.3、7.4	`knowledge-retrieval`、`task-playbook`	P3-02 至 P3-04、P7-04、P8-04	检索包、playbook 记录、第二个任务复用
5	失败、日志、根因、脚本修复与项目/工具/平台知识写回	6.3、7.5	`knowledge-retrieval`、`task-playbook`	P3-01 至 P3-10、P7-08、P8-05	失败候选、知识搜索、文档分析任务
6	二值、证据支撑的完成定义，禁止假完成	5.4、7.6	`completion-gate`	P0-04、P5-01 至 P5-07、P8-05	完成报告、数据库守卫测试、不变量测试
7	人工接管、CLI 会话附着、历史回放与输入	6.7、7.7	`takeover-session`	P6-01 至 P6-06、P7-07、P8-06	接管租约测试、WebSocket 回放、真实接管

#	需求	本文对应	能力增量	主要任务	证明
8	UI 完整匹配平台	第 8 节	`ui-v2`	P7-00 至 P7-13、P8-10	路由契约、视觉检查、截图
9	只允许真实执行，dry-run 不能作为完成证据	4.5、5.5、7.6	`completion-gate`、`toolchain-compatibility`	P5-03、P8-03 至 P8-05	执行回执、真实证据、dry-run 拒绝
10	每个 Agent 的 OpenSpec 上下文、生成配置、需求与评审门	第 9 节	`agent-openspec-config`	P4-07 至 P4-09、P0-01	注册表渲染检查、OpenSpec 校验、写入守卫回执
11	从需求与知识生成好方案、好用例、好结论	5.2、7.9	`knowledge-retrieval`、`completion-gate`	P3-02、P4-01 至 P4-10、P5-04	保证门禁、评审发现、质量指标、E2E

补充说明：需求 4 与需求 5 都依赖 `knowledge-retrieval`，但前者强调任务级检索与 playbook，后者强调失败与知识写回。需求 11 的支撑任务已包含 P4-11 至 P4-13；OpenSpec `tasks.md` 与实施计划均为 81 项。

附录 A 关键术语

术语	本文含义
项目知识库	回答"这个项目怎么测"的方法、口径、指标、词表、场景、项目事实与历史 playbook
工具知识库 lstest	回答"用什么构建与执行"的框架、profile、工具、入口、副作用与工程规范
playbook	一次任务的可复用测试方法包，含需求签名、方案/用例/oracle 哈希、前置、证据要求、结果、失败模式与复用标签
oracle	可独立检查的预期判据，绑定需求、证据来源与分母规则
预执行	在真实设备上验证脚本可执行与环境就绪，不作为完成证据
正式执行	按批准方案采集规定样本与证据的真实运行，可形成完成证据
完成门禁	C1 至 C7 的哈希报告，决定能否写终态
candidate	候选知识，来源和证据已记录，但尚未批准
approved	经评审批准的知识，检索时可作为较高权重证据
接管	对执行会话的受围栏观察或交互控制
C8	"测试之测试"的预留门禁，语义待定，当前不参与判定

附录 B 关联文档

文档	路径	用途
实施计划	`IMPLEMENTATION-PLAN.md`	决策完整版，81 个任务与契约
OpenSpec 提案	`../../openspec/changes/ai-test-platform-v2/proposal.md`	变更理由与范围
OpenSpec 设计	`../../openspec/changes/ai-test-platform-v2/design.md`	D1 至 D13 与冻结契约
OpenSpec 任务	`../../openspec/changes/ai-test-platform-v2/tasks.md`	81 条任务清单，已与实施计划同步
能力规格	`../../openspec/changes/ai-test-platform-v2/specs/`	9 个能力增量
UI 设计	`UI-DESIGN.md`	并行编写，页面与视觉规格
流程图规范	`FLOWCHART-STYLE.md`	一图一问、复杂度预算、形状与颜色约定、模板与反模式
流程图产物	`diagrams/`	图 5-1 / 5-2 的 `.mmd` 源、SVG 与 PNG 渲染件
产品总体方案	`../../../laodengAi/csjh/2026-10-26/00_平台总体方案.md`	产品意图与流程来源
知识库分类	`../../../laodengAi/csjh/2026-10-26/01_知识库分类方案.md`	27 个仓库审计与分类
验证方法论	`../../../laodengAi/knowledge/project/validation-methods/`	需求到脚本、证据、审核、验证池
术语总表	`../../../laodengAi/knowledge/project/glossary/00_术语总表_详细版.md`	术语与测试工程使用规则

附录 C 版本记录

版本	日期	变更
v1.0	2026-10-26	首次汇总产品愿景、角色宪章、架构、主流程、模块、机制、UI 信息架构、治理、路线图、风险与需求追溯